

Global YouTube Statistics

Visão completa sobre o dataset, problemas encontrados, pré-processamento realizado e justificativas técnicas das transformações aplicadas.

01

Tema, Motivação e Problema

O tema do projeto é a **análise de canais do YouTube no contexto global**, cruzando métricas de engajamento e monetização com indicadores socioeconômicos dos países de origem dos criadores.

A motivação vem do fato de que o YouTube movimenta bilhões de dólares anuais em publicidade e é a maior plataforma de vídeo do mundo. Entender o que diferencia canais de alto desempenho — e como fatores como país, categoria e idade do canal se relacionam com crescimento e ganhos — tem valor analítico real tanto para criadores quanto para anunciantes.

O **problema central** é investigar quais características de um canal (e do seu país de origem) se correlacionam com alto engajamento e potencial de monetização, a partir dos 995 maiores canais do YouTube catalogados globalmente.

02

Dataset e Quantidade de Amostras

995

LINHAS (CANAIS)

28

COLUNAS ORIGINAIS

23

COLUNAS APÓS PRÉ-PROC.

0

LINHAS REMOVIDAS

O arquivo `Global YouTube Statistics.csv` reúne os 995 maiores canais do YouTube com dados extraídos diretamente da plataforma e complementados por fontes externas de dados demográficos e socioeconômicos por país.

GRUPO	ATRIBUTOS PRINCIPAIS
Métricas do canal	<code>subscribers</code> , <code>video_views</code> , <code>uploads</code> , <code>video_views_for_the_last_30_days</code>
Monetização	<code>highest_monthly_earnings</code> , <code>lowest_monthly_earnings</code> , <code>highest_yearly_earnings</code> , <code>lowest_yearly_earnings</code>
Metadados	<code>category</code> , <code>channel_type</code> , <code>Country</code> , <code>created_year</code> , <code>created_month</code>
Socioeconômicos	<code>Population</code> , <code>Unemployment_rate</code> , <code>Urban_population</code> , <code>Gross tertiary education enrollment (%)</code>
Geográficos	<code>Latitude</code> , <code>Longitude</code> , <code>Abbreviation</code>
Rankings	<code>rank</code> , <code>video_views_rank</code> , <code>country_rank</code> , <code>channel_type_rank</code>

03

Problemas Encontrados

Valores faltantes generalizados

18 das 28 colunas possuíam ausências. O caso mais crítico foi `subscribers_for_last_30_days` com **337 faltantes (33,9%)**. Dados geográficos e demográficos somavam **123 faltantes (12,4%)** todos concentrados em canais sem país identificado.

Outliers extremos e legítimos

Canais como T-Series (245M inscritos), MrBeast (166M) e Cocomelon (162M) são estatisticamente discrepantes pelo método IQR, mas são registros reais e válidos — não podem ser simplesmente descartados.

Distribuições fortemente assimétricas Métricas de engajamento e monetização seguem lei de potência: a maioria dos canais é pequena e poucos dominam completamente. Isso inviabiliza o uso direto em algoritmos que assumem normalidade.	Multicolinearidade altíssima Diversas colunas de ganhos e rankings tinham correlação de Spearman $\geq 0,99$ entre si, tornando-as completamente redundantes e prejudicando qualquer modelo subsequente.
Encoding corrompido Nomes de canais com caracteres especiais apareciam corrompidos (ex.: "ýýý Kids Diana Show"). Resolvido com detecção automática de encoding via biblioteca chardet.	Caso isolado: Andorra Um canal tinha o país preenchido como Andorra, mas todos os dados demográficos estavam ausentes. Nenhuma estratégia estatística era aplicável — exigiu lookup manual com dados públicos de 2023.

0 4

Pré-processamento Realizado

4.1 — Tratamento de Valores Faltantes

COLUNA	ESTRATÉGIA	JUSTIFICATIVA
<code>category</code> , <code>channel_type</code>	Moda	Variável categórica com classe dominante clara ("Entertainment").
<code>Country</code> / <code>Abbreviation</code>	Sentinela <code>'Unknown'</code> / <code>'UNK'</code>	Sem dado confiável para imputar; sentinela preserva o grupo como categoria válida.
Andorra — geo/demográfico	Lookup manual (dados 2023)	Único caso com país conhecido mas sem dados; fontes públicas disponíveis.
<code>Population</code> , <code>Unemployment rate</code> , etc. (122 casos)	Mediana	Distribuições assimétricas; mediana é robusta a outliers, ao contrário da média.

COLUNA	ESTRATÉGIA	JUSTIFICATIVA
<code>subscribers_for_last_30_days</code> (34%)	Indicador binário + mediana	Alta faltância potencialmente informativa (canais inativos). Flag <code>_missing</code> criado antes da imputação para preservar esse sinal.
<code>country_rank</code> (11,7%)	Indicador binário + sentinela -1	Coluna ordinal; -1 é inequívoco como "sem rank". Flag <code>_missing</code> criado antes.
<code>video_views_rank</code> , <code>channel_type_rank</code> , etc. (<60 casos)	Mediana	Baixa faltância; distribuições assimétricas favorecem mediana.
<code>created_month</code> (5 casos)	Moda	Variável categórica (nome do mês).

4.2 — Tratamento de Outliers

Outliers foram **documentados via IQR e preservados intencionalmente**. Os registros representam canais reais e legítimos — T-Series, MrBeast, Cocomelon. Removê-los enviesaria qualquer modelo em direção a canais de médio porte e eliminaria justamente os casos analiticamente mais interessantes do dataset.

4.3 — Feature Engineering — 6 novas variáveis

FEATURE CRIADA	FÓRMULA	INTERPRETAÇÃO
<code>channel_age</code>	$2023 - \text{created_year}$	Maturidade do canal em anos; mais interpretável que o ano bruto.
<code>views_per_subscriber</code>	$\text{video views} \div \text{subscribers}$	Eficiência de consumo por seguidor.
<code>views_per_upload</code>	$\text{video views} \div \text{uploads}$	Performance média por vídeo publicado.
<code>earnings_spread</code>	$\text{highest} - \text{lowest yearly earnings}$	Volatilidade / amplitude de monetização anual.

FEATURE CRIADA	FÓRMULA	INTERPRETAÇÃO
urban_ratio	Urban_population ÷ Population	Taxa de urbanização do país de origem.
subscriber_growth_rate	subs_30_days ÷ subscribers	Crescimento mensal relativo ao tamanho do canal.

4.4 — Remoção de Features Redundantes

13 colunas foram removidas após análise de correlação de Spearman $\geq 0,97$. Pares identificados: ganhos mensais e anuais tinham correlação $> 0,999$ entre si; rank e subscribers tinham 0,999; Urban_population e Population tinham 0,995.

rank	video_views_rank	channel_type_rank	Abbreviation
lowest_yearly_earnings	highest_yearly_earnings	lowest_monthly_earnings	
created_year	created_month	created_date	Urban_population
			Latitude
Longitude			

4.5 — Transformação Logarítmica

Aplicada $\log_{10}$ em 11 colunas com distribuição de lei de potência (subscribers, video views, uploads, ganhos, crescimento, etc.). A transformação aproxima a distribuição da normal, reduz a dominância dos grandes canais em algoritmos que usam distâncias ou gradientes, e mitiga o efeito residual dos outliers antes da normalização.

05

Normalização — MinMaxScaler vs. StandardScaler

O projeto gerou **dois datasets normalizados em paralelo**, reconhecendo que a escolha do normalizador depende do algoritmo que será aplicado na etapa seguinte.

StandardScaler	MinMaxScaler $DF_MM \cdot INTERVALO [0, 1]$
-----------------------	--

DF_STD · MEDIA 0, DESVIO PADRÃO 1

- Centraliza os dados em torno da média e padroniza a variância para 1.
- Indicado para algoritmos que assumem distribuição aproximadamente gaussiana ou usam distâncias euclidianas: **PCA, SVM, regressão logística, regressão linear.**
- Funciona bem após o log1p porque a distribuição já foi aproximada à normal.
- Não limita valores a um intervalo fixo, portanto outliers residuais ainda têm representação proporcional — vantagem quando eles são informativos.

- Escala todos os valores para o intervalo [0, 1] com base no mínimo e máximo observados.
- Indicado para algoritmos sensíveis à magnitude absoluta ou que exigem entradas limitadas: **KNN, redes neurais, K-Means.**
- Garante que nenhuma feature domine pelo simples fato de ter valores numericamente maiores.
- O log1p prévio é essencial aqui: sem ele, outliers comprimiriam todas as demais observações para valores próximos de zero.

O dataset `df_tratado` (sem normalização, mas com todas as transformações aplicadas) foi mantido como **versão canônica** para análises exploratórias e visualizações que não devem ser distorcidas pela escala.

DATASET	TRANSFORMAÇÕES APLICADAS	USO RECOMENDADO
<code>df_tratado</code>	Limpeza + Feature Eng. + log1p	Análise exploratória, visualizações, correlações
<code>df_std</code>	+ StandardScaler	PCA, SVM, regressão, LDA
<code>df_mm</code>	+ MinMaxScaler	KNN, redes neurais, K-Means

Resumo do Pipeline

#	ETAPA	RESULTADO
1	Detecção de encoding e leitura do CSV	995 × 28 sem caracteres corrompidos
2	Imputação de valores faltantes	0 valores nulos no dataset final
3	Criação de flags de ausência	2 colunas indicadoras adicionadas
4	Documentação de outliers (IQR)	Preservados — canais legítimos
5	Feature engineering	6 novas features derivadas
6	Remoção de features redundantes (Spearman $\geq$ 0,97)	13 colunas removidas
7	Transformação log1p	11 colunas com distribuição corrigida
8	Normalização dupla	df_std e df_mm gerados em paralelo

O dataset passou de **28 para 23 colunas**, mantendo as 995 linhas intactas, com zero valores nulos, distribuições tratadas e três versões prontas para as etapas de modelagem.